

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«ДОНСКОЙ ГОСУДАРСТВЕННЫЙ ТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ»

ЛАБОРАТОРНАЯ РАБОТА № 2

по дисциплине «Машинное обучение»

на тему «Обучение без учителя. Понижение размерности. Обнаружение аномалий. Кластеризация»

Выполнил:

Студент Скрыпник А.В.

Группа ИПБП41

Проверил:

Дольников Максим Геннадиевич

Ростов-на-Дону

2026 г.

Цель работы и исходные данные

Цель лабораторной работы — изучить методы понижения размерности и кластеризации, оценить информативность исходных признаков, выделить значимые и второстепенные компоненты, исследовать работу алгоритмов на данных сложной пространственной формы и определить возможные аномальные наблюдения.

Исследование выполнено по четвёртому варианту на основании файлов Lab2_Dataset_PCA.xlsx и Lab2_Dataset_Clustering.xlsx. В первом наборе используются столбцы S:X (признаки a, b, c, d, e и метки y), во втором — J:L (признаки a, b и метки y). Данные с отсутствующими значениями исключаются. Все исходные признаки перед применением алгоритмов стандартизируются.

Набор данных	Число объектов	Признаки	Эталонные группы
Понижение размерности	194	a, b, c, d, e	y = 0: 97; y = 1: 97
Кластеризация	144	a, b	y = 0: 36; y = 1: 37; y = 2: 36; y = 3: 35

Во всех методах столбец y исключён из обучающих признаков. В первой части он используется только для цветового отображения эталонных групп; во второй — также для заключительного количественного сравнения найденных кластеров. Обучение с использованием эталонных меток не выполнялось.

Используемые средства

Программа написана на Python. Для обработки табличных данных используется pandas, для вычислений — NumPy и SciPy, для моделей — scikit-learn, для графиков — Matplotlib. Исходный скрипт проекта: lab2_variant4.py. При выполнении получаются двенадцать графических файлов PNG в каталоге output, а числовые результаты выводятся в терминал.

Порядок выполнения

Сначала вычисляется матрица корреляций и строится матрица разброса, затем анализируются компоненты PCA, SVD и ICA. После этого сравниваются двенадцать алгоритмов кластеризации, анализируются помеченные как шум точки и проверяется согласованность найденных групп с эталонными метками.

1. Понижение размерности и отбор признаков

1.1. Корреляционный анализ

Для признаков a–e рассчитаны попарные коэффициенты корреляции Пирсона. Наиболее выраженная связь наблюдается между признаками a и c: r(a,c) = 0,544. Остальные попарные коэффициенты по модулю не превышают 0,09, что указывает на отсутствие заметной линейной зависимости между остальными парами признаков.

	a	b	c	d	e
a	1,000	0,008	0,544	−0,025	−0,088
b	0,008	1,000	0,033	0,077	−0,086
c	0,544	0,033	1,000	0,058	0,067
d	−0,025	0,077	0,058	1,000	−0,063
e	−0,088	−0,086	0,067	−0,063	1,000

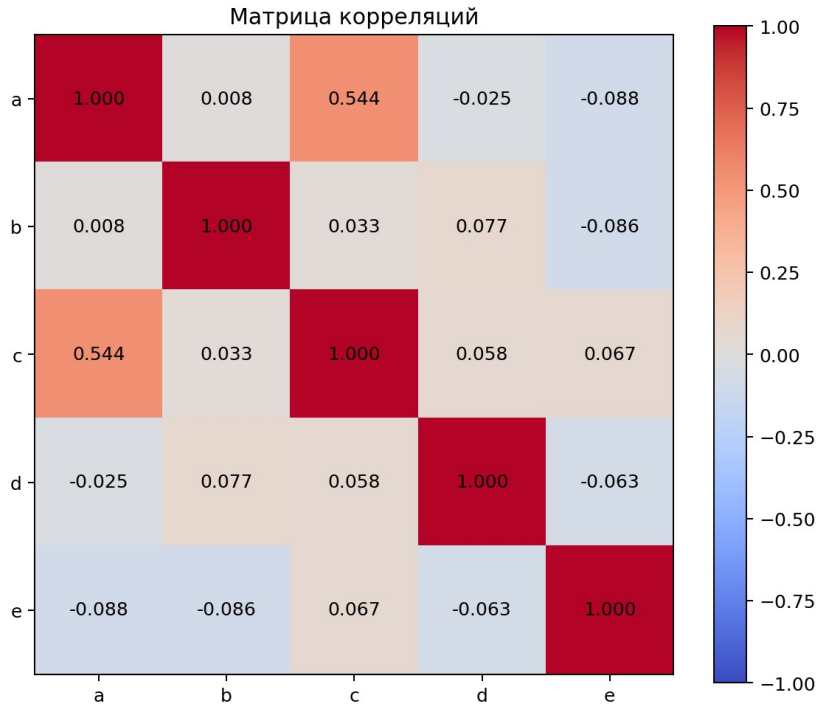


Рисунок 1 — Тепловая карта матрицы корреляций признаков

Связь a и c позволяет предположить частичную избыточность информации: совместное изменение этих признаков описывается одним направлением, а их разность — менее значимым. Проверить это предположение позволяет PCA.

1.2. Матрица разброса признаков

Матрица разброса включает диаграммы рассеяния для всех пар признаков и гистограммы по диагонали. Окраска соответствует y и используется исключительно для наглядности. Наиболее устойчивый линейный тренд заметен для пары a и c; остальные пары характеризуются широким облаком точек без выраженного линейного направления.

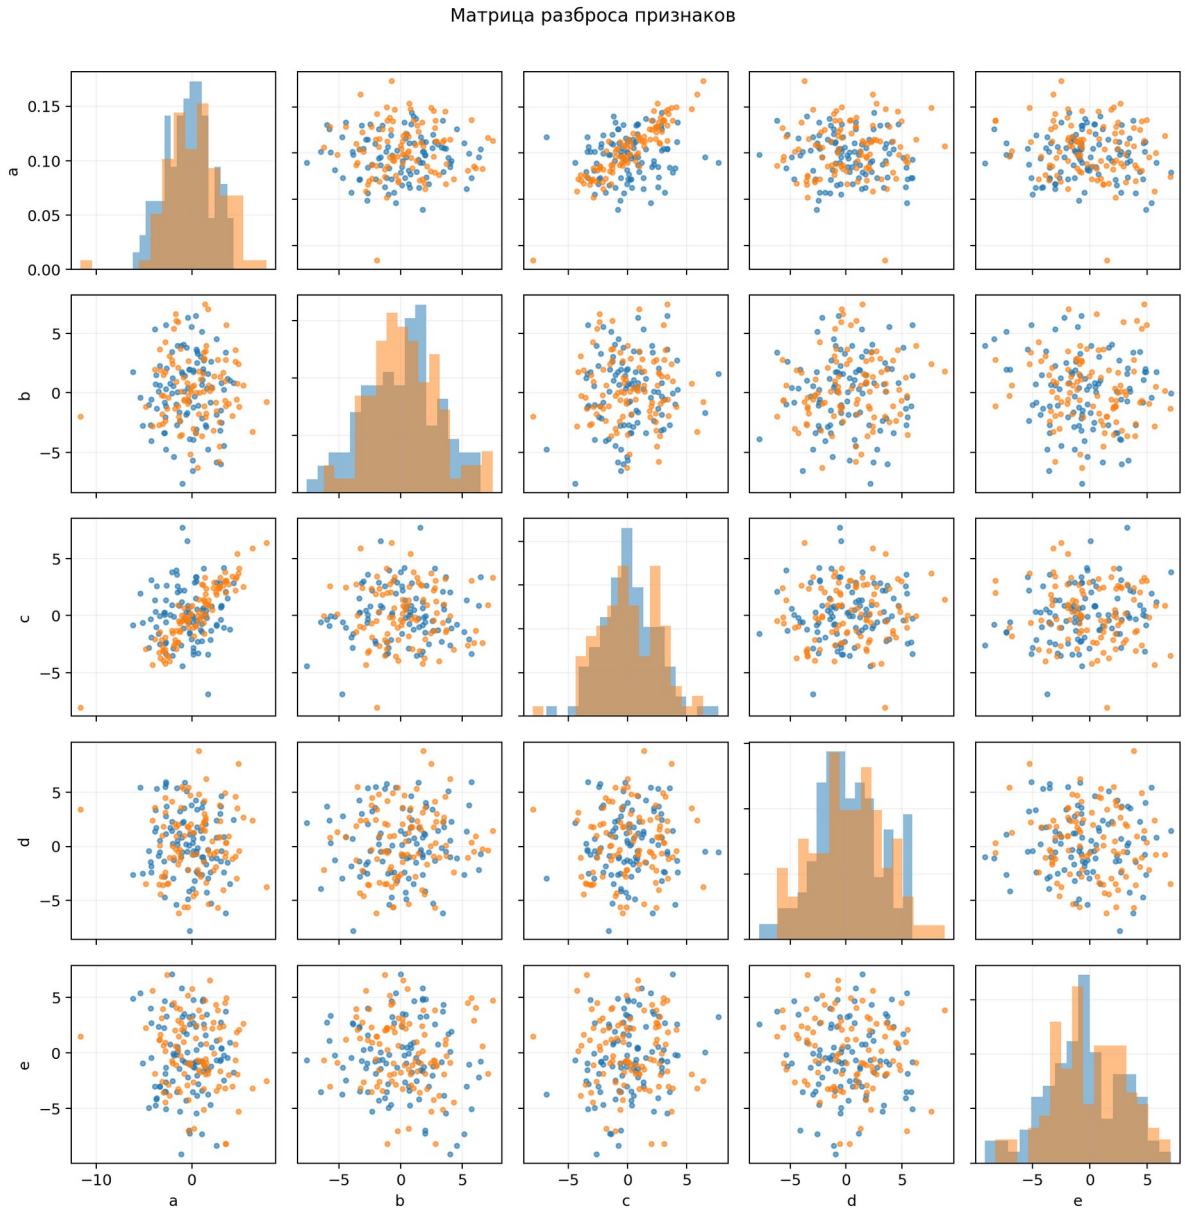


Рисунок 2 — Матрица разброса для пяти исходных признаков

Взаимное перекрытие точек разных эталонных групп показывает, что разделить их одним исходным признаком сложно. Для анализа общей структуры необходимы линейные комбинации исходных переменных.

1.3. Метод главных компонент (PCA)

Перед PCA значения стандартизируются: из каждого признака вычитается среднее, после чего результат делится на стандартное отклонение. PCA находит взаимно ортогональные направления максимальной дисперсии. Их значимость оценивается долей объяснённой дисперсии; сумма долей по всем компонентам равна 100%.

Компонента	Доля дисперсии	Накоплено	Основные нагрузки
PC1	30,97%	30,97%	a = 0,704; c = 0,704
PC2	22,95%	53,92%	b = 0,598; d = 0,534; e = −0,589
PC3	19,30%	73,22%	d = 0,683; e = 0,688
PC4	18,29%	91,51%	b = 0,794; d = −0,481
PC5	8,49%	100,00%	a = −0,686; c = 0,687

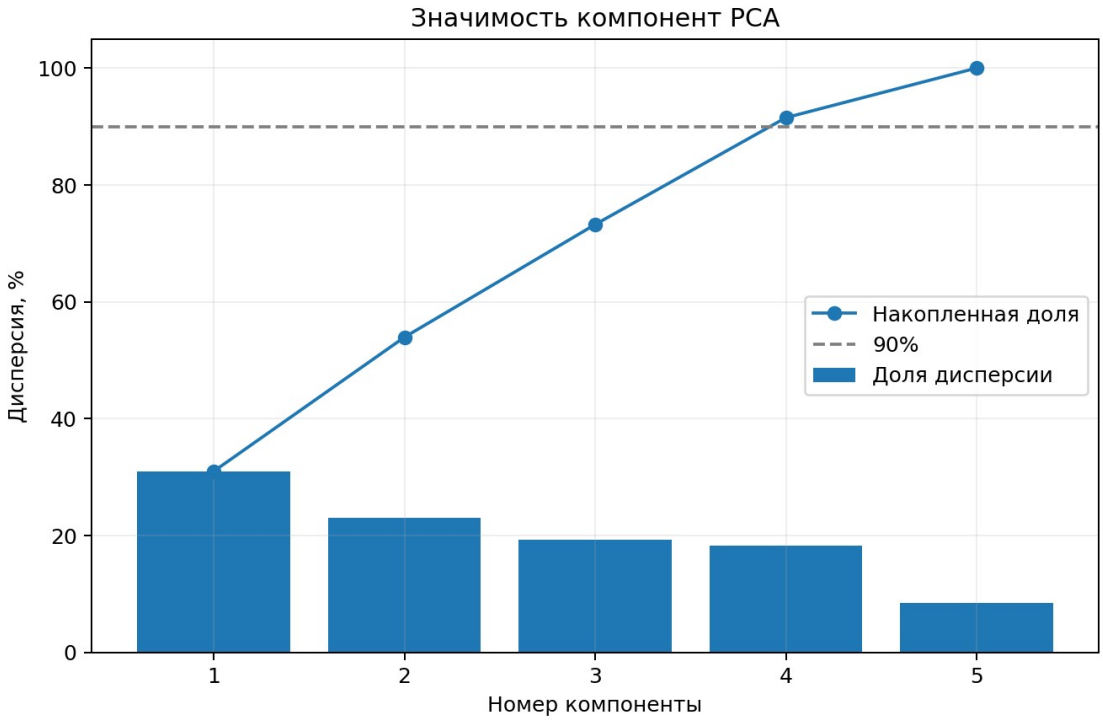


Рисунок 3 — Доля объяснённой дисперсии и накопленная дисперсия PCA

PC1 преимущественно отражает совместное изменение a и c. Последняя компонента PC5, наоборот, задаётся их разностью и объясняет только 8,49% дисперсии. При условии сохранения не менее 90% вариации данных достаточно первых четырёх компонент (91,51%). Первые две сохраняют 53,92% и полезны в основном как двумерное представление.

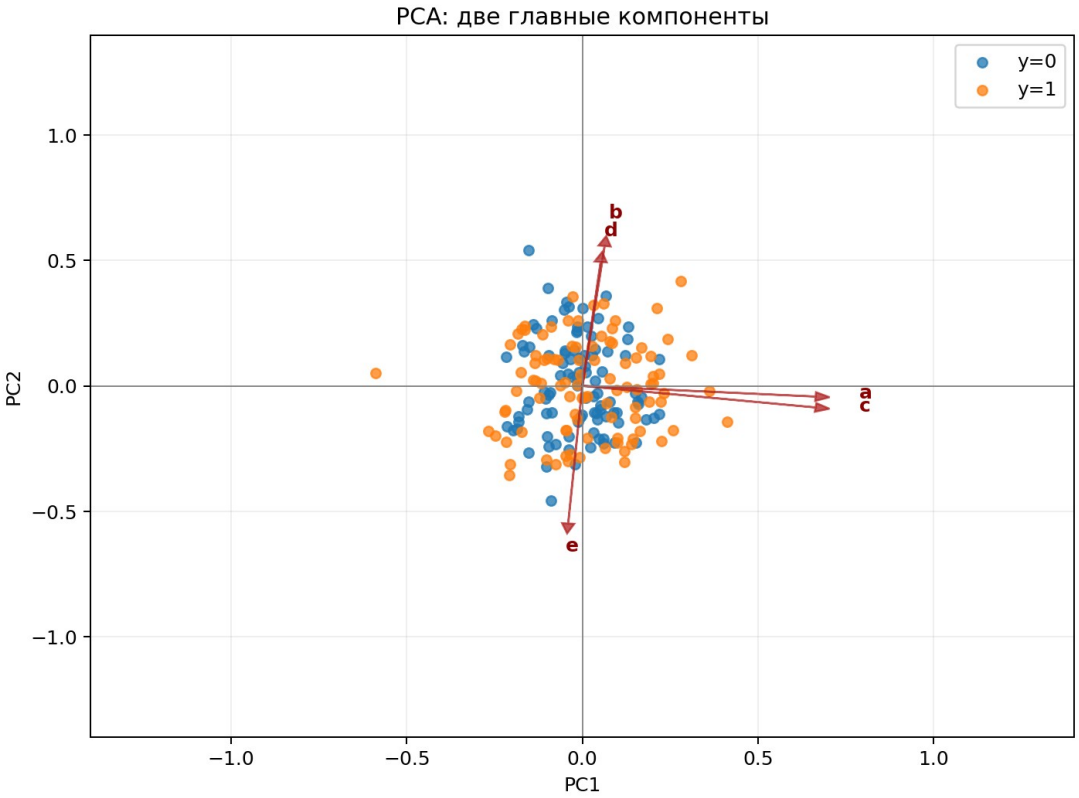


Рисунок 4 — Двумерная проекция PCA с направлениями исходных признаков

На графике направления a и c близки друг к другу, что подтверждает их положительную корреляцию. Вторая ось определяется в основном комбинацией b, d и e. Точки с различными y значительно перекрываются, поэтому сокращение до двух компонент не даёт полного разделения исходных групп.

1.4. Сингулярное разложение (SVD)

Метод SVD разлагает матрицу признаков на произведение трёх матриц с сингулярными значениями и векторами. В проекте TruncatedSVD применяется к той же центрированной и стандартизованной матрице, что и PCA, поэтому направления и доли объяснённой дисперсии совпадают с PCA с точностью вычислений.

Результаты SVD по компонентам: 30,97%, 22,95%, 19,30%, 18,29% и 8,49%. Первые четыре компоненты также сохраняют 91,51% общей дисперсии. Пятая компонента наименее значима.

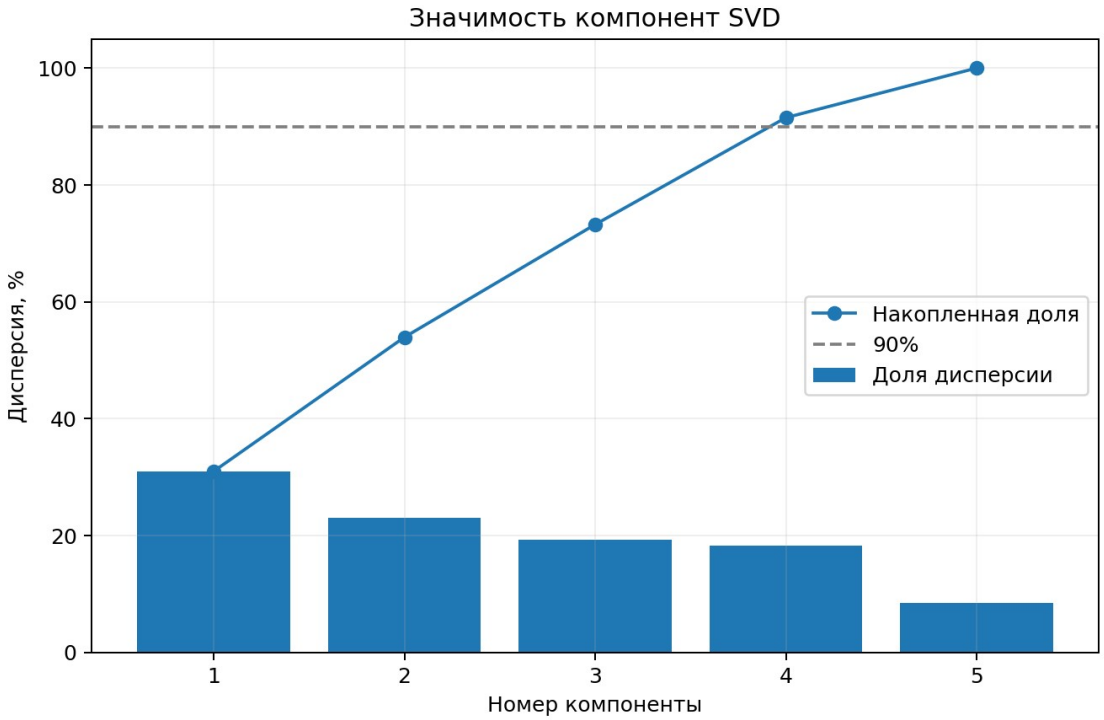


Рисунок 5 — Значимость компонент SVD

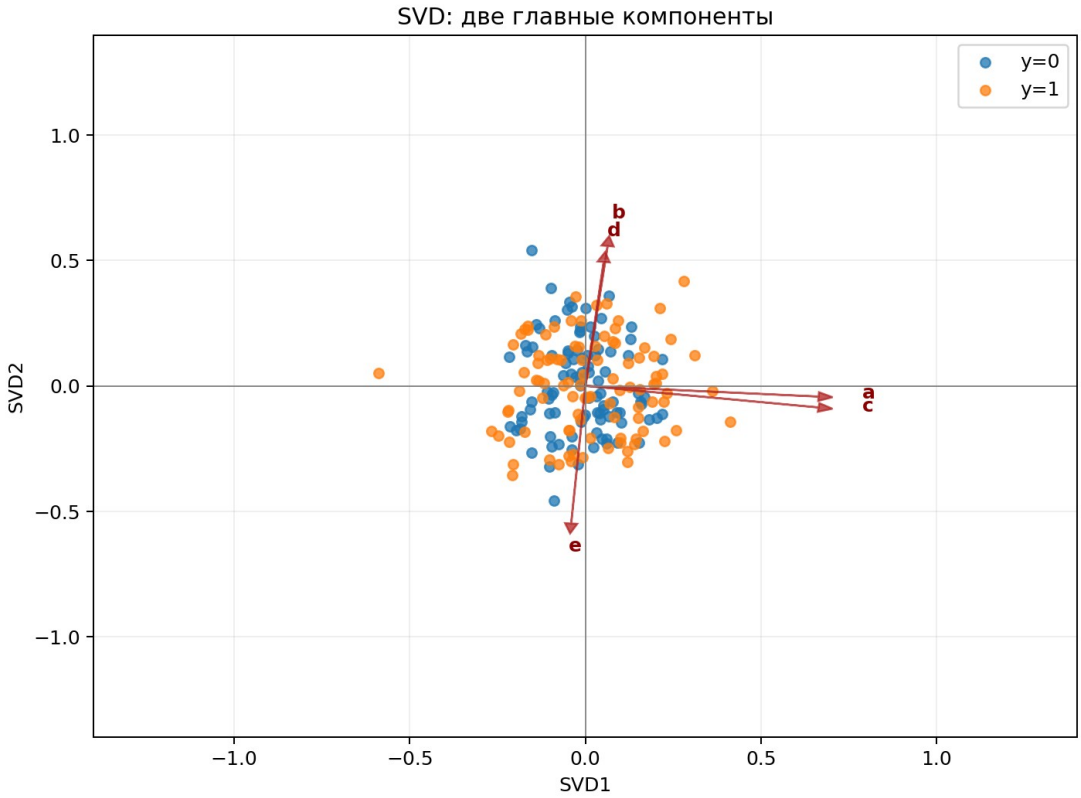


Рисунок 6 — Двумерная проекция SVD с направлениями признаков

Проекция SVD практически совпадает с PCA. Это не ошибка алгоритма, а ожидаемый результат работы с одной и той же центрированной матрицей. SVD подтверждает устойчивость найденной структуры: сильное совместное направление a–c и слабое направление их противопоставления.

1.5. Анализ независимых компонент (ICA)

В отличие от PCA, ICA ищет статистически независимые негауссовские источники. Компоненты FastICA не сортируются по объяснённой дисперсии, поэтому в проекте их значение сравнивается по энергии вклада в реконструкцию стандартизованных признаков. В качестве дополнительной характеристики рассчитан модуль эксцесса: высокое значение показывает отклонение распределения от нормального.

Компонента	Вклад	|Эксцесс|	Интерпретация
IC5	28,92%	1,257	Наибольший реконструкционный вклад
IC4	23,12%	0,691	Второй по величине вклад
IC2	18,54%	0,529	Умеренный вклад
IC1	17,84%	0,492	Умеренный вклад
IC3	11,58%	2,438	Небольшой вклад, высокая негауссовость

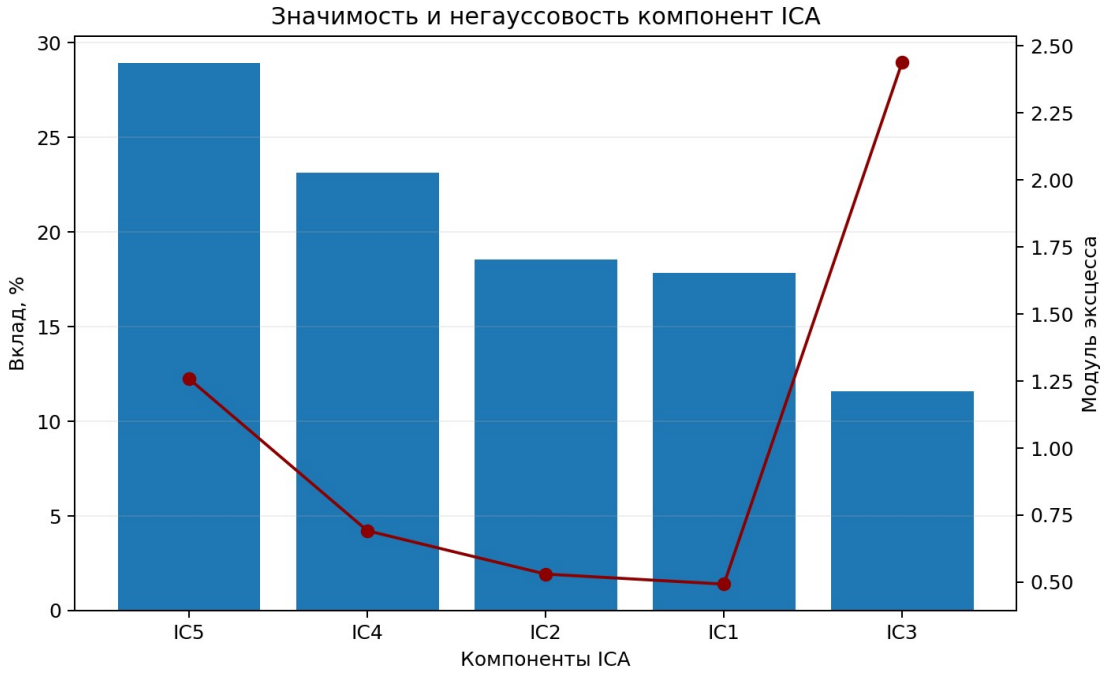


Рисунок 7 — Вклад компонент ICA в реконструкцию и их негауссовость

Две наиболее значимые по выбранной мере компоненты — IC5 и IC4. Их суммарный вклад равен 52,04%. IC2 и IC1 характеризуются средним вкладом. IC3 имеет минимальный вклад (11,58%), но максимальный модуль эксцесса (2,438), поэтому автоматически объявлять её шумовой компонентой некорректно.

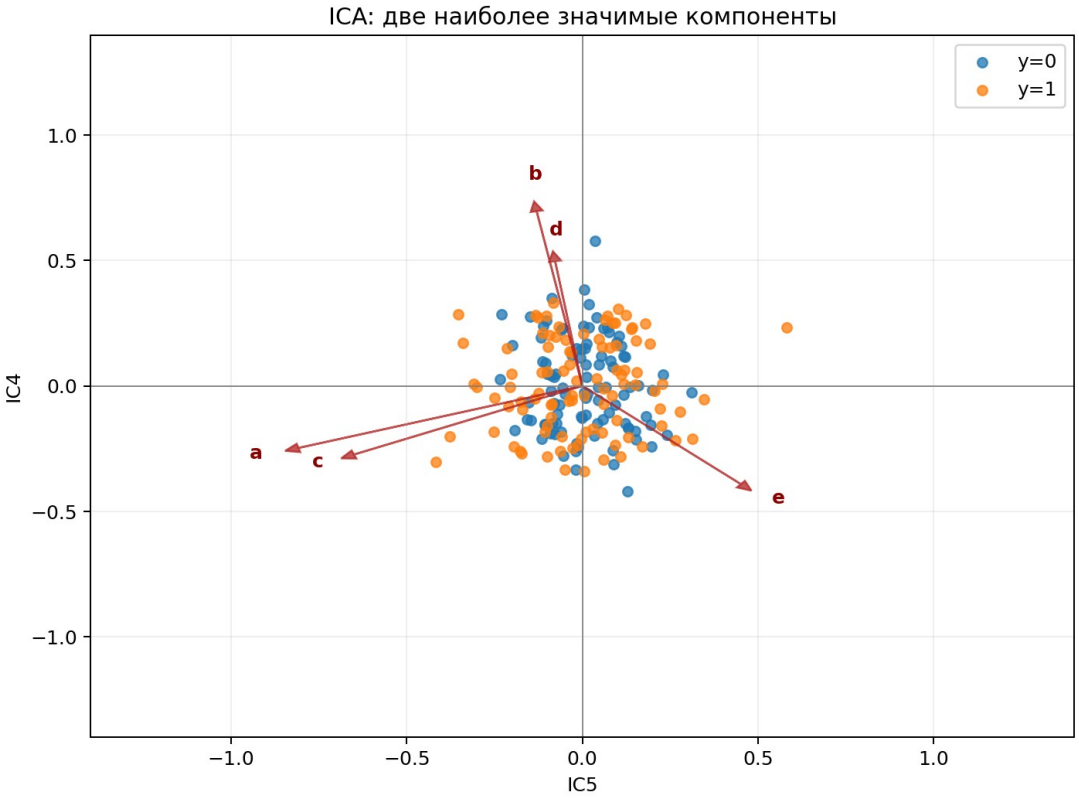


Рисунок 8 — ICA: распределение в координатах IC5 и IC4

Проекция ICA также не разделяет полностью эталонные группы. Векторы a и c ориентированы сходным образом, а b и d преимущественно направлены по второй оси. При этом ICA решает задачу независимости источников, а не максимального разделения классов.

1.6. Классификация компонент и вывод по первой части

Метод	Главные компоненты	Второстепенные	Наименее значимая
PCA	PC1 и PC2	PC3 и PC4	PC5 (8,49%)
SVD	SVD1 и SVD2	SVD3 и SVD4	SVD5 (8,49%)
ICA	IC5 и IC4	IC2 и IC1	IC3 (11,58% по энергии)

При необходимости сократить пять признаков до меньшего числа без существенной потери суммарной дисперсии рационально оставить четыре PCA/SVD-компоненты. PC5 слабо влияет на общую вариацию данных, однако строго назвать её шумом без отдельной модели шума невозможно. Для ICA наиболее слабая по энергии компонента IC3 остаётся заметно негауссовской и также не может быть обоснованно отброшена исключительно как шум.

2. Кластеризация и обнаружение аномалий

2.1. Характер распределения данных и выбор методов

Во второй части исследуется набор из 144 точек с признаками a и b. По графикам в исходной двумерной плоскости наблюдаются несколько пересекающихся вытянутых направлений, то есть кластеры не имеют формы хорошо разделённых круговых облаков. Это

важно при выборе алгоритма: метод, использующий только расстояние до центра, может разрезать вытянутую ветвь или объединить объекты из разных направлений.

Группы различаются не только центрами, но и ориентацией и разбросом. Поэтому для такого набора особенно интересны методы, учитывающие форму ковариационных эллипсов. Одновременно исследуются методы плотности, которые способны присваивать некоторым объектам метку −1 (noise).

2.2. Применённые алгоритмы и параметры

В скрипте использованы все двенадцать алгоритмов из задания. Для методов с фиксированным числом кластеров задано k = 4. Affinity Propagation и Mean Shift настроены так, чтобы на рассматриваемых данных выделять четыре группы. Ниже приведены параметры, указанные в проекте.

Алгоритм	Основные параметры
K-Means	n_clusters=4; n_init=50
Affinity Propagation	damping=0,7; preference ≈ −28,351
Mean Shift	bandwidth ≈ 0,967
Spectral Clustering	n_clusters=4; nearest_neighbors; n_neighbors=10
Ward	n_clusters=4; linkage=ward
Agglomerative	n_clusters=4; linkage=complete; metric=cosine
DBSCAN	eps=0,28; min_samples=4
HDBSCAN	min_cluster_size=12; min_samples=2
OPTICS	min_samples=5; xi=0,08; min_cluster_size=12
Gaussian Mixture	n_components=4; covariance_type=full; n_init=50
BIRCH	n_clusters=4; threshold=0,459; branching_factor=20
Bisecting K-Means	n_clusters=4; n_init=20

По особенностям алгоритмов ожидается, что K-Means, Ward и Bisecting K-Means будут предпочитать компактные области; Affinity Propagation и Mean Shift могут делить распределение по локальным максимумам плотности; Spectral Clustering, Agglomerative, DBSCAN, HDBSCAN и OPTICS зависят от связности или локальной плотности. Gaussian Mixture с полной ковариацией может моделировать сильно вытянутые кластеры с разной ориентацией.

Сводный график построен в проекте единой сеткой plt.subplots(3, 4). Для читаемости в отчёте показаны три последовательных фрагмента этого рисунка, по четыре алгоритма в каждом.

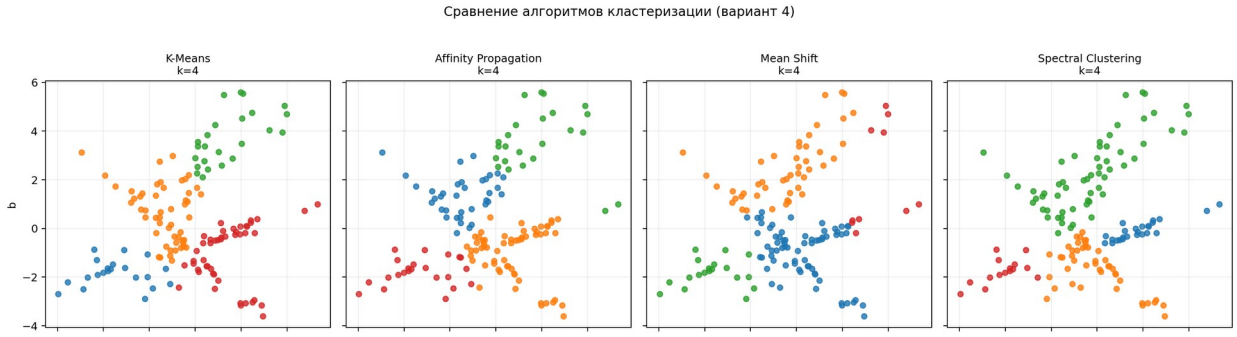


Рисунок 9 — Сравнение: K-Means, Affinity Propagation, Mean Shift, Spectral Clustering

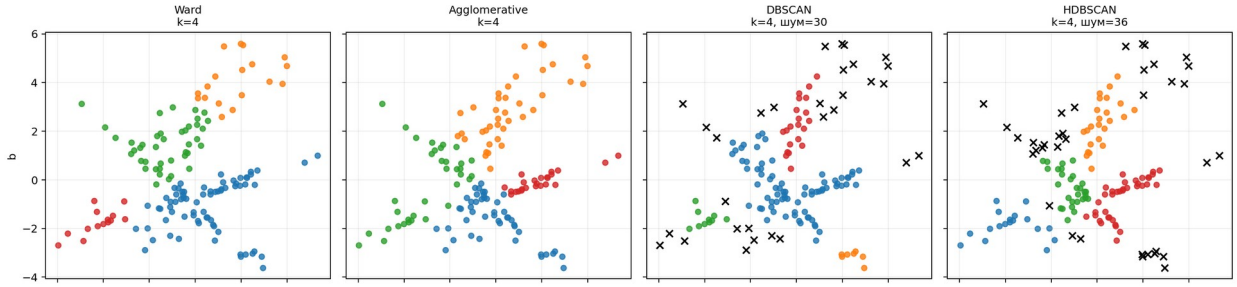


Рисунок 10 — Сравнение: Ward, Agglomerative, DBSCAN, HDBSCAN

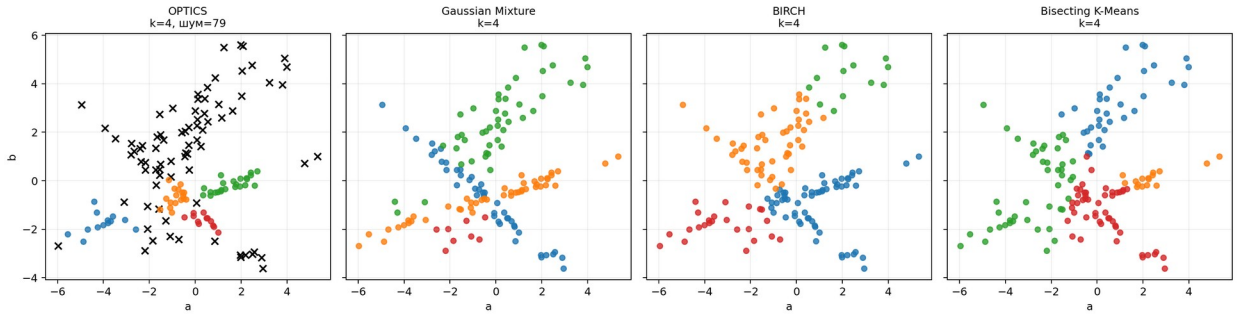


Рисунок 11 — Сравнение: OPTICS, Gaussian Mixture, BIRCH, Bisecting K-Means

По рисункам видно, что K-Means, Ward и BIRCH делят область на компактные сегменты, частично смешивая направления. Спектральный метод выделяет часть протяжённых структур, но не полностью восстанавливает их. В GMM группы тянутся вдоль основных ветвей, что соответствует характеру распределения. Плотностные алгоритмы обнаруживают отдельные фрагменты ветвей, одновременно исключая много разреженных точек как шум.

2.3. Оценка плотностных методов и обнаружение выбросов

В алгоритмах DBSCAN, HDBSCAN и OPTICS метка −1 означает, что наблюдение не включено ни в один выделенный кластер при выбранных параметрах. Это индикатор низкой локальной плотности, но не доказательство того, что наблюдение некорректно.

Алгоритм	Кластеров	Noise, точек	Noise, %	Silhouette без noise
DBSCAN	4	30	20,83%	0,351
HDBSCAN	4	36	25,00%	0,465
OPTICS	4	79	54,86%	0,571

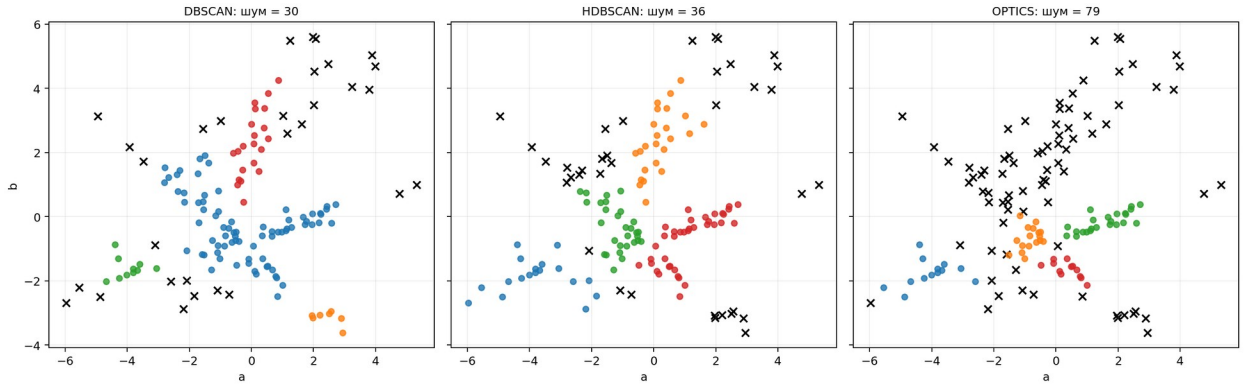


Рисунок 12 — Сравнение найденных кластеров и noise-точек плотностных методов

DBSCAN пометил шумом 30 объектов из 144, HDBSCAN — 36, OPTICS — 79. Значение Silhouette у OPTICS выше остальных, но эта метрика рассчитана без noise-точек. Поэтому большое значение здесь частично объясняется тем, что большая доля трудных объектов не участвует в расчёте. Сравнивать силуэт без учёта доли шума некорректно.

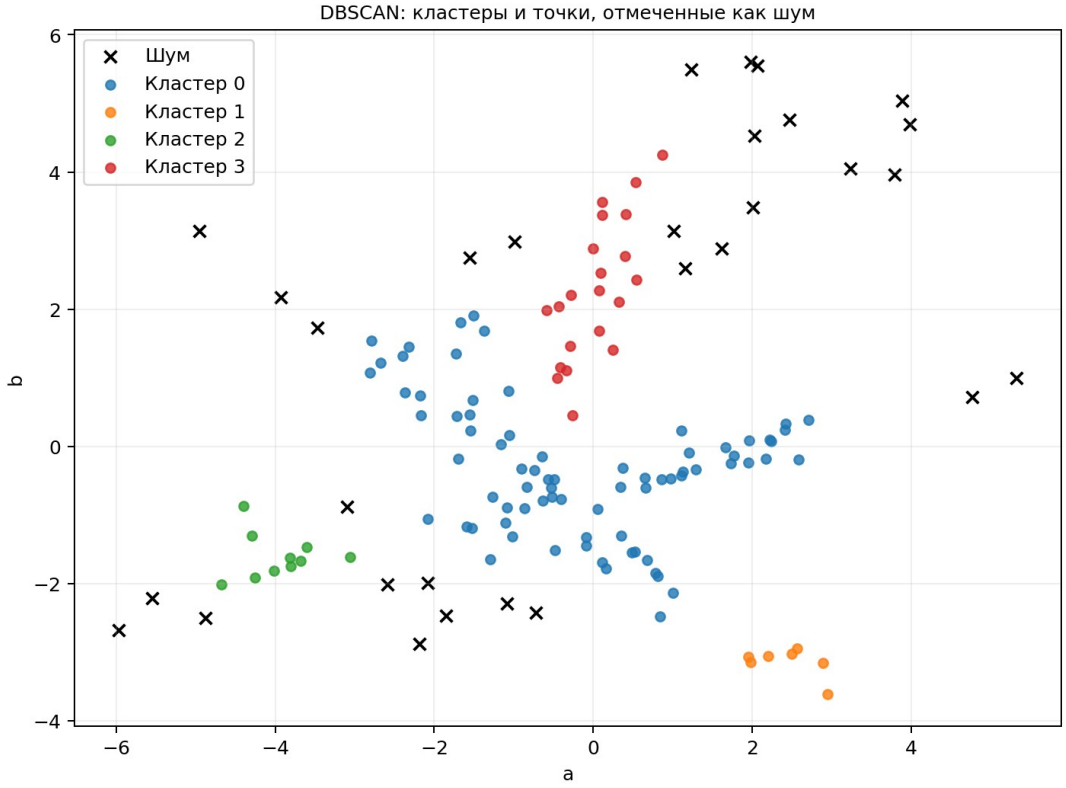


Рисунок 13 — Кластеры DBSCAN; чёрные крестики обозначают потенциальные выбросы

На отдельной диаграмме DBSCAN видно, что ряд объектов, помеченных как шум, располагается на продолжениях вытянутых кластерных ветвей, где плотность ниже. Поскольку исходный набор содержит четыре обычных эталонных класса, а специальной метки аномалий в нём нет, эти наблюдения нельзя считать подтверждёнными выбросами. Для данной геометрии плотностные методы применимы скорее к поиску малоплотных областей, чем к полному восстановлению всех групп.

2.4. Количественное сравнение с эталонными метками

Для проверки качества результатов использованы ARI (Adjusted Rand Index) и NMI (Normalized Mutual Information). Эти показатели сравнивают разбиение с эталоном и не

зависят от перестановки номеров кластеров. Также рассчитана доля совпадений после оптимального взаимно-однозначного сопоставления номеров найденных групп с номерами эталонных классов. Метрика Silhouette используется только как внутренняя оценка компактности и разделённости по расстояниям.

Алгоритм	k	Noise	Silhouette	ARI	NMI	Совпадение, %
Gaussian Mixture	4	0	0,070	0,561	0,575	77,78
Agglomerative	4	0	0,336	0,293	0,387	56,94
Spectral Clustering	4	0	0,317	0,272	0,370	52,08
Bisecting K-Means	4	0	0,331	0,175	0,276	47,92
Ward	4	0	0,390	0,172	0,325	45,83
Mean Shift	4	0	0,360	0,167	0,257	45,83
OPTICS	4	79	0,571	0,160	0,273	45,14
BIRCH	4	0	0,398	0,159	0,291	42,36
K-Means	4	0	0,402	0,152	0,263	45,83
Affinity Propagation	4	0	0,410	0,152	0,258	45,14
HDBSCAN	4	36	0,465	0,144	0,240	38,89
DBSCAN	4	30	0,351	0,089	0,228	38,89

Лучший результат по ARI получил Gaussian Mixture: ARI = 0,561, NMI = 0,575, доля совпадений 77,78%. Далее следуют агломеративная кластеризация с косинусной метрикой (ARI = 0,293) и Spectral Clustering (ARI = 0,272). Минимальное значение ARI у DBSCAN — 0,089. При интерпретации ARI для методов с noise метка −1 считается отдельным результатом кластеризации, как это реализовано в скрипте.

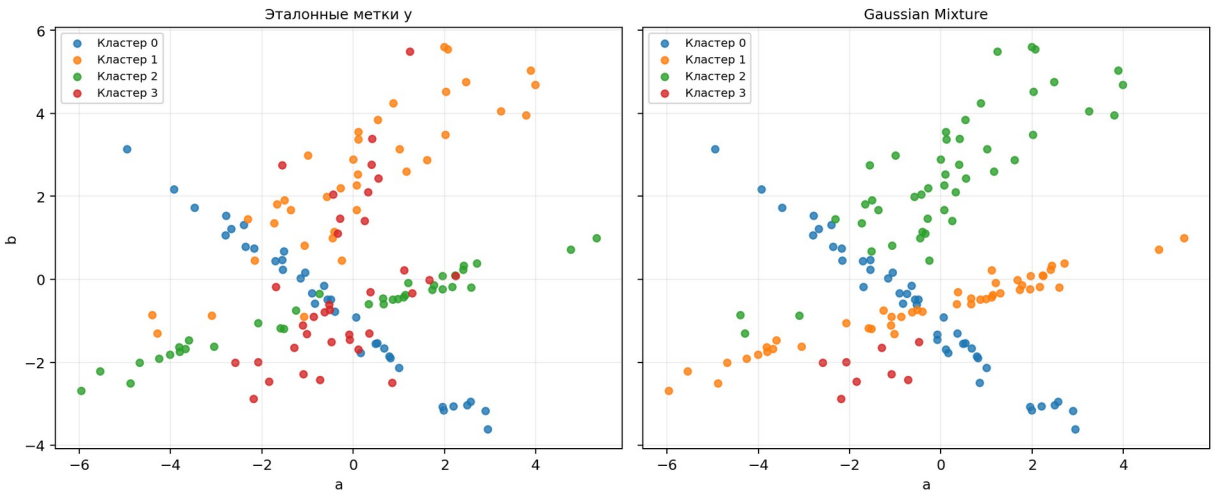


Рисунок 14 — Эталонная разметка и результат Gaussian Mixture

GMM с полной ковариационной матрицей допускает вытянутые эллиптические компоненты различных ориентаций и потому лучше других воспроизводит три протяжённые ветви. Основная сложность связана с широкой центральной группой, которая заметно перекрывается с остальными направлениями. В результате модель не может полностью восстановить эталонное разбиение.

Значение Silhouette для GMM составляет только 0,070, несмотря на лучшие ARI и NMI. Противоречия здесь нет: силуэт оценивает близость точек на основе расстояния и лучше подходит для компактных, разделённых кластеров, тогда как в этом наборе группы пересекаются и отличаются ковариационной формой. Для выбора наиболее подходящего алгоритма на данном наборе при наличии эталонной разметки ARI и NMI показательнее.

2.5. Выбор наиболее эффективного алгоритма

Наиболее эффективным из рассмотренных методов для четвёртого варианта признан Gaussian Mixture с четырьмя компонентами и полной ковариационной матрицей. Этот метод лучше приспособлен к различным наклонам и вытянутости кластеров. Достижение 77,78% совпадений при ARI = 0,561 показывает, что структура восстановлена частично, но не идеально. Для плотностных алгоритмов основной проблемой стало большое число исключённых разреженных объектов; для центроидных — разбиение вытянутых ветвей на близкие к сферическим части.

Заключение

В ходе выполнения лабораторной работы проанализирован набор пяти признаков методами корреляционного анализа, PCA, SVD и ICA, а также сравнены двенадцать методов кластеризации двумерного набора данных.

Корреляционный анализ показал умеренную связь a и c (0,544). PCA и SVD согласованно установили, что первые четыре компоненты сохраняют 91,51% дисперсии, а последняя объясняет только 8,49%. ICA выделил главные по реконструкционному вкладу компоненты IC5 и IC4, которые суммарно дают 52,04%; при этом IC3, несмотря на меньший энергетический вклад, обладает выраженной негауссовостью.

Во второй части установлено, что пересечение и вытянутость кластеров существенно влияют на результаты алгоритмов. Наилучшее соответствие эталону получил Gaussian Mixture (ARI = 0,561; NMI = 0,575; совпадение 77,78%). Методы DBSCAN, HDBSCAN и OPTICS пометили часть наблюдений как шум, но отсутствие отдельного эталонного класса аномалий не позволяет считать эти объекты доказанными выбросами.

Таким образом, выбор метода должен учитывать геометрию распределения: для пересекающихся вытянутых групп полезно моделирование полных ковариаций, а результаты плотностных методов следует оценивать с учётом доли неотнесённых точек.

Использованные материалы

Методические указания: «Лабораторная работа 2. Обучение без учителя. Понижение размерности. Обнаружение аномалий. Кластеризация».

Исходные данные проекта: Lab2_Dataset_PCA.xlsx, Lab2_Dataset_Clustering.xlsx (вариант 4).

Программная реализация проекта: lab2_variant4.py; графики из каталога output.

Документация библиотек scikit-learn, SciPy, NumPy, pandas и Matplotlib (программные средства, использованные в проекте).